

Самаркандский государственный университет им. Шарофа Рашидова

Лекция Л2

Анатомия текстовых данных и среда разработки Cursor

Анализ художественного текста с помощью ИИ и цифровых технологий

Алексеев П. В., доктор филологических наук, профессор

Магистратура · Литературоведение (русская литература)

К концу лекции вы сможете...

1. почему качество цифрового анализа наследует качество входного файла
2. что такое кодировка UTF-8 и чем опасны ошибки OCR и смешение редакций
3. когда нужны TXT, XML и JSON
4. как устроена работа в Cursor как исследовательской среде

Garbage in — garbage out

Красивый график на грязных данных —
не открытие, а аккуратно оформленная ошибка.

Сначала контроль формы данных: издание · кодировка · источник · что удалено.

Оцифровка — всегда абстрагирование

Перевод объекта (рукописи, печатного издания, изображения страницы) в цифровую форму. Выбираются одни свойства и отбрасываются другие — фактура бумаги, цвет чернил, иногда орфография при «исправляющем» OCR. Цифровой файл — модель текста через цепочку решений.

Л2 · дефиниция оцифровки; ср. электронное издание (TEI) vs рабочий аналитический файл.

«Грязные данные» выглядят цифровыми — и потому опасны

- OCR-мусор, неверная кодировка, колонтитулы и номера страниц
- метки сайта, смешение редакций, неснятая HTML/XML-разметка
- ломают частоты и стилиометрию сильнее спора о тропе
- храните raw · clean · analysis-ready и лог решений между ними

Л2 · [WRITE] три версии файла; риск «уже цифрового» = «уже точного».

Минимум текстовой гигиены курса



- Гигиена кодировок: знать исходную → UTF-8 → проверить ё, кавычки, тире → не менять без записи в лог.

Какой формат когда

TXT (plain text)

- плоский текст без обязательной разметки
- старт частотного анализа
- каноническая рабочая копия курса

XML / TEI

- структура: глава, стих, реплика
- TEI — стандарт электронных изданий
- нужен, когда важна разметка, не только буквы

JSON

- сущности, ответы API, таблицы
- удобен для NER и LLM-конвейеров
- не усложняйте формат раньше вопроса

DOCX/PDF удобны человеку, но плохи как единственный аналитический источник.

Токенизация — исследовательское решение

Токенизация — сегментация текста на единицы анализа (слова, знаки, иногда предложения). Нет «нейтрального» слова: граница токена, регистр, дефис и «ё» задают пространство частот. RegEx — формальный шаблон поиска/преобразования; ИИ ускоряет правила, но не знает вашей жанровой специфики.

Л2 · токен и RegEx; контрольная выборка до/после обязательна.

Один фрагмент — два профиля «частот»

Close: что видно глазами

Объект: глава/рассказ до очистки.

Вопрос: какие токены — издательский мусор?

Доказательство: сверка с изданием, не «красота» топа.

Риск: колонтитул «Собрание» в голове Zipf-списка.



Падение «мусора» после правил — условие анализа, не результат о поэтике.


Учебная схема Л2; на практике топ считается на вашем UTF-8 файле.

Cursor как лаборатория: три практики

- Папки: /texts · /scripts · /output · /notes (source.md, cleaning.md)
- Контекст через @Files — не пересказ сюжета модели
- Маленькие шаги: фрагмент → таблица → полный текст
- Критерий готовности скрипта: устно объяснить каждый шаг человеку без кода

Л2 · учебный каркас папок; файл в texts/ — источник истины, не чат.

Cursor — среда работы, не замена паспорту файла



Скриншот интерфейса Cursor Desktop (cursor.com, 2026). Агент и редактор — инструмент лаборатории; источник истины остаётся файл в /texts.

cursor.com · учебный снимок интерфейса, не инструкция к коду.

Запрос к модели о коде

Запрос-настроение

- «сделай красиво / глубоко»
- нет входа, выхода, ограничений
- модель охотно изобразит глубину

Запрос-архитектура

- цель · входной файл · ожидаемый выход
- ограничения · критерий проверки
- проверяемая процедура, не «настроение»

ИИ ускоряет правила очистки; решение «что мусор» остаётся филологическим.

Возражения и рабочий ответ

«В литературоведении всегда была уникальность интерпретации»

Да. Но уникальность $\neq$ непрозрачность процедуры. Оригинальное чтение совместимо с честным логом частот.

«Модернизируем язык через ИИ — так удобнее»

Не модернизируйте «на глаз» и не поручайте модели «сделать современным» без raw-копии и осознанного решения.

«Код запускается — значит считает то, что нужно»

Запуск $\neq$ смысл шагов: что слово, что удаляется, куда пишется результат — сверяйте явно.

Л2 · [ATTN]; семинар C2 начинается с вопросов «на какой файл смотрела модель».

Тройка рядом с любым графиком

Источник → процедура (скрипт/промпт) → лог решений.

Минимум метаданных: кто, что за текст, откуда, когда, какая версия, что уже сделано.

После Л2: папки проекта, raw-текст, source.md, понимание UTF-8, готовность к П1.

Три формулы · что читать

1. Garbage in — garbage out: график на грязных данных — оформленная ошибка.

2. Raw → clean → analysis-ready; между ними — лог решений.

3. Рядом с графиком всегда тройка: источник → процедура → лог.

К следующей встрече — ориентиры

- Дж. Дракер (Drucker). The Digital Humanities Coursebook — данные как конструкция.
- СФУ 2023 / ИТМО 2021 — разделы о подготовке текстовых данных.
- TEI Consortium. TEI P5 Guidelines — идея разметки электронных изданий.
- Документация Cursor — среда, не замена паспорту файла.

К практике П1


Одностраничный протокол

- (a) установить Cursor; папки /texts /scripts /output /notes
- (b) глава/рассказ в UTF-8 TXT в /texts
- (c) notes/source.md: издание, URL/путь, дата, ограничения
- (d) на практике — скрипт длины и топа токенов

На занятии

Где в вашем файле граница между «удобной чисткой» и потерей жанрового сигнала?

Логика семестра



Сначала контроль формы данных — потом спор об интерпретации цифр.