

Самаркандский государственный университет им. Шарофа Рашидова

Лекция Л3

Основы корпусной филологии и предобработка текста

Анализ художественного текста с помощью ИИ и цифровых технологий

Алексеев П. В., доктор филологических наук, профессор

Магистратура · Литературоведение (русская литература)

К концу лекции вы сможете...

1. отличить корпус от случайного набора файлов по критериям отбора, метаданных и воспроизводимости
2. объяснить разницу исследовательского и эталонного корпуса
3. ориентироваться в базовых возможностях НКРЯ и Google Books Ngram Viewer как инфраструктур дальнего чтения
4. описать пайплайн «источник → очистка → нормализация → измерение → интерпретация»

Корпус сам по себе не «говорит»

Смысл появляется, когда филолог задаёт вопрос
и документированную процедуру измерения.

Папка = файлы. Корпус = файлы + правило отбора + метаданные + подготовка.

Корпус (в цифровой филологии)

Организованная совокупность текстов (и/или размеченных единиц), собранная по явным критериям отбора, снабжённая метаданными и предназначенная для проверяемых исследовательских процедур — не просто «много файлов в папке».

ЛЗ · дефиниция корпуса; Ф. Моретти (Moretti) — серия/система как единица знания.

Два типа корпусов

Исследовательский

- собран под ваш вопрос
- авторский / жанровый / сравнительный
- не обязан «представлять весь язык»
- обязан быть сопоставимым внутри себя


Эталонный (референсный)

- инфраструктура для многих задач
- для русского — НКРЯ как центральный пример
- фон, норма, материал для гипотез
- не заменяет ваш корпус идиостиля

Сначала дизайн корпуса (автор / жанр / внутренний), потом сбор файлов — не наоборот.

Паспорт корпуса: шесть обязательных полей

Паспорт корпуса: без него «большой корпус» слеп




Большой корпус без паспорта хуже малого с ясной выборкой.

Репрезентативность, смещение, метаданные

- Полная репрезентативность почти недостижима — важна честная формула ограничений
- Bias: канон vs периферия, столица vs провинция, сетевые копии vs академические издания
- В паспорте: что включено, что исключено, почему, какие издания, какие смещения
- Имена файлов — для человека; таблица метаданных — для измерения

ЛЗ · [WRITE] паспорт корпуса; Дж. Дракер (Drucker): данные — конструкция.

Пайплайн корпусной работы



- Нет интерпретации без паспорта предобработки. Нет паспорта — нет науки, есть демо.

Токен · лемма · стоп-слова — решения, не «тutorial»

Токенизация

- граница слова, регистр, дефис, «ё»
- одна и та же для всех текстов сравнения
- записать правило в /notes

Лемматизация

- тема / bag-of-words → чаще леммы
- форма может быть стилистически важна
- для Delta — осторожно с агрессией морфологии

Стоп-слова

- никогда не удалять «по умолчанию»
- частицы могут быть ключом интонации
- список фиксировать, если удаляете

Не существует нейтральной токенизации — есть согласованная с вопросом.

Один вопрос — два режима корпуса


Close: сцена / фрагмент

Объект: ирония в диалоге одной главы.

Вопрос: как сделан смысл здесь?

Доказательство: троп, чужая речь, композиция.

Корпус не обязателен — обязателен текст.



Пики → возврат к главам пристальным чтением (логика Моретти).

Учебная схема ЛЗ; метрика на практике — только на вашем издании и паспорте.

Смещение канона видно на схеме


Что проверить до подсчётов

годы и жанр выборки

доля канонических авторов

единица: текст или глава

вопрос, под который собран корпус



Учебный эскиз: десятилетия «перетягивают» долю текстов.

ЛЗ · bias корпуса

Инфраструктуры фона

НКРЯ

- размеченные контексты, морфология
- фон и норма языка
- не заменяет корпус вашего автора/издания

Google Books Ngram Viewer

- исторические кривые частот
- генератор гипотез, не автомат истины
- OCR и смещения корпуса — читать критически

Ngram Viewer = фоновые кривые; поэтика доказывается на вашем корпусе и цитатах.

НКРЯ: лексико-грамматический поиск как инфраструктура фона



Корпус

Основной

• 140 804 текста • 426 186 466 слов
синтаксически размечен, омонимия снята

Подкорпус

Задать

Поиск точных форм

Поиск коллокаций

Лексико-грамматический поиск

По умолчанию поиск ведется по предпочтительным разборам, соседние слова могут совпадать.

Поиск учитывает:

- ☐ все разборы
- ☒ предпочтительные разборы

При поиске:

- ☐ совпадения соседних слов исключаются
- ☒ соседние слова могут совпадать

Национальный корпус русского языка: основной корпус, лемма «тоска» (ruscorpora.ru, 2026). Фон и норма языка — не замена вашего издания.

ruscorpora.ru · снимок формы поиска, не результат измерения по курсу.

Типичные возражения

«Большой корпус всегда лучше маленького»

Большой корпус без метаданных хуже малого с паспортной карточкой каждого файла.

«НКРЯ уже всё посчитал — зачем свой корпус?»

НКРЯ даёт фон. Вопрос об идиостиле на вашем издании требует исследовательского корпуса.

«Разметим иронию и сказ автоматически»

Разметка всегда theory-laden: документируйте схему тегов и спорные случаи.

ЛЗ · [ATTN]; инвестиция в паспорт окупается на Л4–Л12.

Правило выбора нормализации

Вопрос	Чаще леммы	Чаще словоформы
Тематический словарь / bag-of-words	да	редко
Ритм служебных слов / Delta	осторожно	да (аккуратно)
Грамматика поэтики	нет	сохранение форм

Решение записывается в preprocessing.md до измерения.

Проверочный вопрос аудитории

Чем ваш мини-корпус отличается от папки «интересного»?

Назовите критерий отбора раньше, чем число файлов.

Формула ЛЗ

Корпус = правило отбора + данные + подготовка.

Цифра законна только внутри этой формулы.

Сначала паспорт предобработки — потом частота, Zipf и Delta.

Три формулы · что читать

1. Папка = файлы; корпус = файлы + правило + метаданные + подготовка.

2. Пайплайн: источник → очистка → нормализация → измерение → интерпретация → текст.

3. Нет паспорта предобработки — нет науки, есть демо.

К следующей встрече — ориентиры

- Ф. Моретти (Moretti). Дальнее чтение — серия и система форм.
- Дж. Дракер (Drucker). The Digital Humanities Coursebook — данные как конструкция.
- ИТМО 2021 / СФУ 2023 — корпусная логика и предобработка.
- НКРЯ (ruscorpora.ru) — инфраструктура фона, не замена вашего корпуса.

К практике / семинару

Одностраничный протокол

- (a) мини-корпус 3–5 текстов/глав одного автора (UTF-8)
- (b) таблица метаданных: автор, год, издание, raw/clean
- (c) /notes/preprocessing.md: токен, леммы, стоп-слова
- (d) один вопрос, который корпус может проверить — и один, который нет

На занятии

Какое смещение вашего «удобного» собрания классики вы готовы назвать вслух?

Логика семестра



Любая частота наследует токен и лемму — кривой токен красиво опишет кривизну.