

Самаркандский государственный университет им. Шарофа Рашидова

Лекция Л4

Квантитативные методы и закон Ципфа

Анализ художественного текста с помощью ИИ и цифровых технологий

Алексеев П. В., доктор филологических наук, профессор

Магистратура · Литературоведение (русская литература)

К концу лекции вы сможете...

1. объяснить закон Ципфа как регулярность распределения частот и понять, что «обычный» Zipf-профиль — норма, а не...
2. построить и прочесть частотный словарь (ранг–частота)
3. объяснить, почему TTR зависит от длины текста и как сравнивать тексты честно
4. различить частотные слова и ключевые слова

Частоты не объясняют роман

Они дают карту повторов и отличий —
по которой идут к интерпретации и цитате.

Частота законна только относительно: предобработки, длины, фона и вопроса.

Закон Ципфа (Zipf's law)

В классическом приближении частота слова обратно пропорциональна рангу: $f(r) \approx C / r^\alpha$ (α часто близко к 1). «Голова» сверхчастых + длинный «хвост» редких — норма языка и длинного текста, а не автоматически «стиль автора» или доказательство гениальности.

Л4 · Zipf как диагностическая рамка; Дж. Ципф — степенные регулярности сложных систем.

Ngram Viewer задаёт фон частот, не закон стиля

Google Books Ngram Viewer

тоска,скука

1800 - 2019

Russian (2019)

Case-Insensitive

Smoothing

0.00120%

0.00110%

0.00100%

0.00090%

0.00080%

0.00070%

0.00060%

0.00050%

Google Books Ngram Viewer: «тоска» / «скука», корпус Russian (2019), 1800–2019. Кривая — генератор гипотез; поэтика доказывается на вашем корпусе и цитатах.


books.google.com/ngrams · учебный снимок, не измерение курса.

0.00020%

0.00010%

Ловушка TTR: длина диктует «богатство»

TTR падает с длиной — сравнивать сырые TTR нельзя




Л4 · количественные ловушки

Частотный словарь: что подписывать

- Абсолютная частота f vs относительная (доля от N токенов)
- Ранг r : позиция при упорядочивании по убыванию частоты
- Гапакс (hapax) — единица ровно один раз
- В подписи: словоформа/лемма; регистр; стоп-слова; чему равна относительная частота

Л4 · [WRITE] частота законна только относительно процедуры.

Диагностический порядок Л4



- Сначала сопоставимость, потом эффект, потом интерпретация.
- Zipf-график в приложении — диагностика данных; как «главный результат о поэтике» — почти никогда.

Что часто ≠ что характерно

Частые слова

- топ токенов / лемм
- каркас употреблений
- часто служебный слой
- облако на сыром топе — вредная «наглядность»

Ключевые слова (keywords)

- относительно reference corpus
- кандидат в отличие, не ярлык смысла
- дальше — конкорданс и чтение
- keyword без фона — риторика, не метод

Коллокация = совместная встречаемость выше ожидаемой; дальше — ручное чтение контекстов.

TTR и ловушка длины

- $TTR = |types| / |tokens|$ — интуиция «лексического разнообразия»
- TTR падает с длиной текста: новелла vs роман «в лоб» сравнивать нельзя
- Правило курса: окна равной длины или иной выравнивающий дизайн
- «У автора А словарь богаче, потому что TTR выше» — подозрительно без окон

Л4 · скользящее/оконное измерение для сопоставимости и динамики.

Zipf как диагностика, не приговор стилю


Что подписать на графике

лемма или словоформа

стоп-слова: да/нет

чему равна частота

длина текста N



Голова сверхчастых + хвост редких — норма языка.

Л4 · закон Ципфа

Zipf-профиль как sanity check


Close: что проверить глазами

Объект: топ-20 словоформ после очистки.

Вопрос: голова — язык или колонтитул?

Доказательство: сверка с изданием + лог.

Норма Zipf $\neq$ открытие поэтики.



Голова + спад — ожидаемо; ищем изломы, мусор и отличие от контроля.

Учебная схема Л4; на практике — таблица ранг–частота на вашем UTF-8 тексте.

Частые методологические ловушки

«Облако слов доказало тему романа»

Облако на сыром топе без решения о признаках внушает наглядность там, где ещё нет метода.

«Служебные слова метафизически значимы сами по себе»


Не интерпретируйте их через метафизику, пока не проверили общеязыковой фон.

«Частота идеологического слова = позиция автора»

Это повод открыть контекст точки зрения, а не ярлык «автор думает так».

Л4 · [ATTN]; частоты — язык вопроса о повторе и отличии, не окончательного смысла.

От таблицы к аргументу



Что писать в отчёте

- подпись: словоформа/лемма, стоп-слова, N
- что в топе — норма языка
- что — кандидат в эффект
- конкорданс рядом с числом

Л4 · фраза без графика + конкорданс уже доказательна.

Что закон Ципфа не доказывает

Похожие ранговые распределения бывают в разных сложных системах.

Факт zipfian-профиля почти ничего не говорит об уникальности поэтики.

Мост к стилиометрии (Л5)

Авторский сигнал часто сидит в пропорциях высокочастотных служебных единиц.

Но прежде Delta исследователь обязан убедиться: частоты не описывают грязь файла.

Диагностика Л4 — входной контроль лаборатории перед атрибуцией.

Три формулы · что читать

1. Zipf: голова сверхчастых + хвост редких — норма, не автомат «стиля».

2. Не сравнивать TTR разной длины без выравнивания окон.

3. Диагностика: предобработка → Zipf/топ → аномалии → интерпретация → цитаты.

К следующей встрече — ориентиры

- Ф. Моретти (Moretti). Дальнее чтение — масштаб количественного взгляда.
- ИТМО 2021 / СФУ 2023 — количественные методы в ДН.
- Обзоры Zipf's law в корпусной лингвистике (учебные главы).
- Voyant / AntConc / Counter — инструменты; подпись процедуры обязательна.

К практике / семинару

Одностраничный протокол

- (a) частотный словарь словоформ (топ-20) + CSV полного Counter
- (b) Zipf-список ранг–частота для топ-50
- (c) окна равной длины: сравнить TTR
- (d) 10–15 предложений: норма языка vs кандидат в аномалию

На занятии

Какой токен из топа вы готовы объявить мусором — и почему?

Логика семестра



Сначала сопоставимость, потом эффект, потом интерпретация.