

Самаркандский государственный университет им. Шарофа Рашидова

Лекция Л5

Стилиометрия и атрибуция авторства

Анализ художественного текста с помощью ИИ и цифровых технологий

Алексеев П. В., доктор филологических наук, профессор

Магистратура · Литературоведение (русская литература)

К концу лекции вы сможете...

1. объяснить, что такое стилиометрия и чем она отличается от «интуиции стиля»
2. понять роль высокочастотных служебных слов как носителей авторского сигнала
3. изложить идею меры Burrows' Delta на уровне исследовательской интуиции (без требования вывести матричную алгебру)
4. описать роль корпуса сравнения и опасность грязных данных

Близость профилей ≠ доказанное авторство

Это гипотеза при данных признаках и данных текстах —
а не приговор суда и не «ИИ угадал автора».

Стилиометрия отвечает на сходство профилей; литературовед решает, что оно значит.

Стилиометрия (stylometry)

Совокупность количественных методов анализа стиля: тексты представляются наборами измеримых признаков и сравниваются как объекты в признаковом пространстве. Авторский инвариант (рабочая формула курса) — относительно устойчивый набор характеристик письма при контроле жанра и эпохи.


Л5 · stylometry; нет универсального инварианта «на все жанры».

Почему служебные слова (function words)?

- Тема сидит в хвосте частот; авторский сигнал часто — в голове
- Высокочастотные грамматические единицы труднее «играть» сознательно
- Только после очистки и жанрового контроля
- Драма, лирика и романная проза одного автора могут расходиться сильнее, чем проза современников

Л5 · [WRITE]; фиксируйте тип повествования в метаданных comparison corpus.

Интуиция Burrows' Delta



- Дж. Бёрроуз (Burrows): меньшее расстояние — большая стилистическая близость относительно корпуса сравнения.
- Атрибуция без comparison corpus — детективный жест, не метод.

Burrows J., 2002; детали формулы — на практике, смысл — на лекции.

Что контролируем

Корпус сравнения

- тексты с известным авторством
- желательно близкий жанр / период
- одинаковая предобработка — критично
- мало кандидатов → слабый вывод

Грязные данные / жанр

- смешение редакций ломает Delta
- унификация орфографии может стереть сигнал
- короткая эпиграмма «в лоб» — почти всегда шум
- Voyant без паспорта Л2–Л4 столь же опасен

На экзамене важнее объяснить процедуру и ограничения, чем формулу без смысла.

Два кандидата — учебное расстояние


Close: что читать в выбросе

Объект: спорный фрагмент + 2 автора.

Вопрос: ближе к А или к В при MFW?

Доказательство: таблица + ограничения.

Язык: «профиль ближе к корпусу Х...».



Нижний бар у A2 — повод к гипотезе, не к приговору.


Учебная схема Л5; реальная Delta — на вашем comparison corpus.

Voyant Tools: педагогический мост

- Открытая веб-платформа частотного и визуального сравнения
- Удобна для учебного distant reading и первичного Contrasts
- Не заменяет специальный метод и паспорт предобработки
- Подпись к рисунку: Voyant Trends / таблица MFW / Burrows Delta

Л5 · Voyant — мост, не оракул авторства.

Voyant Tools: облако и reader — мост, не приговор авторства



Voyant Tools: Cirrus / Reader / Summary по Pride and Prejudice (Project Gutenberg). Частоты и облако требуют паспорта Л2–Л4.

voyant-tools.org · Sinclair & Rockwell · учебный снимок интерфейса.

Этический минимум языка атрибуции

«Доказано, что написал X»

Замените: «профиль ближе к корпусу X, чем к Y при данных признаках и данных текстах».

«Отрицательный результат — провал»

Неуверенный результат при прозрачной процедуре — научный результат.

«ИИ уверенно назвал автора»

Постановка кандидатов, comparison corpus, чтение выбросов и формула вывода — человеческие.

Л5 · М. П. Ив (Eve): ответственность за то, что измеряется и почему это релевантно.

Что может маскироваться под «авторский сигнал»

Фактор	Риск	Контроль
Жанр / форма	драма ≠ проза одного автора	comparison того же жанра
Рассказчик / роль	ложный инвариант голоса	метаданные типа повествования
Редакция / OCR	профиль грязи, не стиля	паспорт Л2–Л4

Короткий текст (эпиграмма) — почти всегда повод ослабить вывод, а не усилить.

Формула осторожной речи

«Профиль ближе к корпусу X, чем к Y
при данных признаках и данных текста».

Стилиометрия в системе доказательств

В магистерской работе — аргумент, а не приговор суда.

Близость профилей = гипотеза (авторство / жанр / эпоха / редакция / рассказчик).

Одинаковая предобработка кандидатов и спорного текста — условие метода.

Три формулы · что читать

1. Стилиметрия сравнивает профили; смысл сходства решает литературовед.
2. Тема — в хвосте; авторский сигнал часто — в голове частот (после очистки).
3. Этический язык: ближе к корпусу X при данных признаках — не «доказано, что X».

К следующей встрече — ориентиры

- Дж. Бёрроуз (Burrows). “Delta”: a Measure of Stylistic Difference... (2002).
- М. П. Ив (Eve). The Digital Humanities and Literary Studies (2022).
- ИТМО 2021 / СФУ 2023 — обзор quantitative literary studies.
- Voyant Tools — учебный интерфейс; паспорт Л2–Л4 обязателен.

К семинару / практике


Одностраничный протокол

- (a) два коротких текста разных авторов одного жанра (UTF-8, одна очистка)
- (b) таблица относительных частот 20–30 общих MFW
- (c) Voyant или эквивалентная таблица сравнения
- (d) абзац вывода без «доказано»; список ограничений

На занятии

Чей вывод осторожнее — и где спрятан жанровый конфаунд?

Логика семестра



Близость профилей — гипотеза; ответственность за формулировку — филологическая.