

Самаркандский государственный университет им. Шарофа Рашидова

Лекция Л6

Извлечение именованных сущностей (NER) в художественном тексте

Анализ художественного текста с помощью ИИ и цифровых технологий

Алексеев П. В., доктор филологических наук, профессор

Магистратура · Литературоведение (русская литература)

К концу лекции вы сможете...

1. объяснить задачу NER и отличие именованной сущности от «просто существительного»
2. привести пример из логики пособия ИТМО о разнице между нарицательным и именованным употреблением
3. понимать возможности экосистемы Natasha для русского текста
4. предвидеть типичные ошибки NER на художественной литературе (прозвища, уменьшительные имена, мифонимы, говорящие...

Список сущностей — не зеркало смысла

NER отвечает: какие именованные объекты упомянуты и где.

Филолог решает: кого слить в канонические узлы и зачем.

Без кореференции/нормализации граф персонажей врёт.

NER (Named Entity Recognition)

Извлечение именованных сущностей — автоматическое обнаружение в тексте упоминаний сущностей определённых типов (персона, локация, организация и др.) и их маркировка. Именованная сущность — объект, обозначенный именем собственным или устойчивым именованием, позволяющим отождествлять экземпляр across упоминаний. Упоминание (mention) — конкретный span («Алёша», «младший Карамазов»).

Л6 · пример логики ИТМО: «корабль» vs корабль «Мария».

Обработать (Shift+Enter)

Упоминание и узел

Mention / span


- сырой фрагмент распознавателя
- «Алёша», «Алексей», «брат»
- ошибки: прозвища, мифонимы
- уменьшительные и говорящие фамилии

Канонический узел

- один персонаж / место — один ID
- словарь: вариант → канон → тип
- кореференция решается чтением
- спорные случаи — в примечании

Правило узла: канон + список вариантов; пропуск среднего звена = фантомное знание.

Пайплайн Л6



- Natasha — учебный конвейер для русского: сегментация, морфология, NER.
- Сначала литературоведческая нормализация места — потом решение о геокодинге.

Типичные ошибки на художественном тексте

- Прозвища, уменьшительные, мифонимы, говорящие фамилии
- Омонимия разных персонажей с одним именем
- Автоматический string similarity («Алёша≈Алексей») — подсказка, опасный автопилот
- Частота упоминания $\neq$ иерархия персонажной системы

Л6 · [ATTN]; precision vs recall — оптимум зависит от задачи.

Семья без нормализации vs с нормализацией

Close: слияние вручную

Объект: «Алёша / Алексей / инок».

Вопрос: один узел или толпа?

Доказательство: таблица вариантов.

Без словаря сеть будет врать.

NER: сырые spans до нормализации узлов

Алёша сказал Алексею Фёдоровичу, что брат Иван ждёт в Москве.

PER
Алёша

PER
Алексею Фёдоровичу

PER
Иван

LOC
Москве

Без словаря нормализации «Алёша» и «Алексей...» = два узла

Падение числа узлов после словаря — условие графа, не «открытие поэтики».

Учебная схема Л6; на практике — ваша таблица нормализации ≥ 10 вариантов.

Precision · Recall · задача

Высокая полнота

- меньше пропусков
- больше фантомов в сети
- удобно для разведки упоминаний

Высокая точность

- меньше мусора
- граф может быть «дырявым»
- важнее для карты ключевых топосов

Филологический выбор

- оптимум под вопрос
- не «максимум F1 ради F1»
- ошибки автоматике описать явно

Совстречаемость в главе ≠ дружба/конфликт: это гипотеза контактной зоны.

Границы автоматики

«NER-тег = итог поэтики персонажа»

Метка модели — гипотеза распознавателя. Не переносите её в теорию без рефлексии.

«Склеим всех Алексеев автоматически»

Можно склеить разных людей. Спорные случаи решаются чтением.

«Геокодинг сразу по сырым LOC»

Сначала нормализация места (real/fictional/uncertain), потом — если нужно — геокодинг.

ЛБ · [WRITE] упоминание → тип → канон → отношение/карта.

Словарь нормализации (учебный минимум)

- Поля: вариант упоминания → канонический узел → тип → примечание
- Для LOC: канон, варианты, тип (real / fictional / uncertain), комментарий
- Первая проверка вывода — нет ли мусора инфраструктуры (не «кто главный»)
- Ручная доразметка — норма метода, не поражение автоматике

Л6 · JSON удобен для хранения сущностей; файл важнее чата.

Микроупражнение на узлы

Сведите «Саша / Шура / Александр Иванович» к одному узлу.

Какое имя каноническое для вашей работы — и почему?

Мост к сетям (Л7)

Без нормализации имён метрики центральности бессмысленны.

«Князь Андрей», «Болконский», «Андрей» как три узла — артефакт пайплайна.

1) clean текст и паспорт; 2) mentions; 3) словарь узлов — иначе граф не начинать.

Три формулы · что читать

1. NER: какие именованные объекты и где; узлы решает филолог.

2. Без кореференции/нормализации граф персонажей врёт.

3. Упоминание → тип → канон → карта/сеть; пропуск звена = фантомное знание.

К следующей встрече — ориентиры

- Natasha (natasha.github.io) — экосистема NLP для русского.
- Ф. Моретти (Moretti). Дальнее чтение — карты и модели как горизонт после сущностей.
- ИТМО 2021 — логика данных и извлечения сведений.
- СФУ 2023 — цифровая филология: обзорные главы.

К практике / семинару


Одностраничный протокол

- (a) извлечь PER/LOC из рассказа/главы; сохранить сырой список
- (b) таблица нормализации ≥ 10 вариантов имён/топонимов
- (c) описать 3 ошибки автоматике
- (d) один вопрос для сети персонажей + один для карты пространства

На занятии

Какой вариант имени вы делаете каноном — и почему не наоборот?

Логика семестра



Без таблицы нормализации результат NER не принимается как завершённый.