

Самаркандский государственный университет им. Шарофа Рашидова

**Лекция Л9**

# Тематическое моделирование (Topic Modeling) и LDA

Анализ художественного текста с помощью ИИ и цифровых технологий

**Алексеев П. В., доктор филологических наук, профессор**

Магистратура · Литературоведение (русская литература)

## К концу лекции вы сможете...

1. объяснить topic modeling как модель совстречаемости терминов и смеси тем в документе
2. сформулировать интуицию LDA без тяжёлой математики
3. отличить статистический кластер от литературоведческого мотива
4. собрать таблицу верификации темы и учесть риски предобработки, имён собственных и неустойчивости параметров

## Алгоритм не знает сюжета

Он предлагает гипотезы о повторяющихся полях слов.

**Мотив начинается только после проверки эпизодами.**

*Topic modeling = генератор гипотез, не автомат мотивов.*

## Тема в topic modeling

Вероятностное распределение над словарём: одни слова для данной темы более вероятны, другие — менее. На практике исследователь видит тему как список опорных (топовых) терминов. Слово «тема» здесь техническое — его нельзя автоматически переносить в язык мотивоведения без процедуры именования.

*Д. М. Блей, Э. И. Нг, М. И. Джордан (Blei, Ng, Jordan), LDA, 2003*

# Тема LDA — мешок слов, не ярлык романа

Тема LDA  $\neq$  «тема романа»: это мешок со-встречаемых слов



Сначала список слов и контексты, потом осторожное имя темы.

## Документ как смесь тем

Единица корпуса, представленная как смесь тем в разных долях. Документом может быть глава, рассказ, статья, абзац — выбор исследовательский и входит в паспорт метода. Смена единицы документа часто сильнее влияет на результат, чем «тонкая» настройка гиперпараметров.

## LDA — интуиция без тяжёлой математики

Latent Dirichlet Allocation: документы — смеси латентных тем, темы — распределения по словам.

Априорные распределения Дирихле задают «разреженность»: документ обычно не смешивает все темы сразу. LDA отвечает, какие слова склонны идти вместе — и не отвечает, какой это мотив в системе производства.

# Мотив ≠ статистический кластер

## Мотив (литературоведение)

- Повторяющийся значимый элемент
- Включён в сюжетно-символическую систему
- Требуется чтения традиции и тропа
- Имя даётся после доказательства

## Тематический кластер (LDA)

- Устойчивая совстречаемость терминов
- Может совпасть с мотивом частично
- Может быть артефактом имён / рутины
- Сначала слова и главы — потом имя

Персонажный кластер — не «ошибка LDA». Ошибка — выдать его за мотив.

## Петля интерпретации Л9



- Умение убить плохую тему важнее умения назвать красивую.
- LDA без времени на отказ — почти всегда ретрофит.

# Динамика тем по главам


## Как читать теплокарту

столбец = тема (T1...)

строка = глава

яркий пик → открыть главу

k и предобработка в паспорте



Теплокарта — гипотеза о композиции; проверка — чтением.

# Таблица верификации темы

| Поле         | Что фиксируете     | Зачем              |
|--------------|--------------------|--------------------|
| Топ-слова    | 10–15 терминов     | Ядро кластера      |
| Документы    | 2–3 главы-якоря    | Где поле реально   |
| Имя-кандидат | рабочая гипотеза   | Не финальный ярлык |
| Сомнения     | шум / имена / жанр | Столбец обязателен |

Без столбца «сомнения» тема на семинар C10 не принимается.

## Предобработка решает почти всё

- Смена лемматизатора и стоп-слов меняет темы сильнее «тонкой» настройки K.
- Не смешивайте лемматизированные и сырые документы в одном корпусе.
- Колонтитулы, сноски, HTML и неотфильтрованные имена дают мусорные «темы».
- В паспорт: лемматизатор, версия, решение об именах и цифрах.
- Устойчивость = узнаваемое ядро при умеренной смене параметров и повторных запусках.

*Связь с гигиеной данных Л2–Л3 прямая.*

## Учебный эскиз: доля темы C2 по главам

### Как читать такой ряд


Высота — условная доля темы в документе

Пик в гл. 3 и 7 — зона проверки

Низ в гл. 5 — не «отсутствие мотива»

Сначала топ-слова, потом имя C2

Связь с Ф. Моретти: масштаб повторов



учебный эскиз · K и seed не заданы

Сила LDA — неочевидные повторы. Слабость — нет понимания сюжета. Мост — вы.

## Три ловушки именования

### Ретрофит красивым ярлыком

Сначала придумали «мотив вины», потом подогнали топ. Правильный порядок: слова → документы → имя-кандидат → чтение → отказ или уточнение.

### Мусорный топ как открытие

Топ из колонтитулов и цифр требует возврата к очистке, а не литературного имени.

### «Алгоритм выявил мотивы»

Пишите: вероятностная модель выделила лексические кластеры; после проверки предлагаем интерпретировать C2 как поле...

*М. П. Ив (Eve): без литературного вопроса сравнение долей пусто.*

## Вопросы к корпусу

**Что в этом топе может быть артефактом?**

Где имена собственные маскировать, а где выносить в отдельный слой?

Готовы ли вы убить одну «красивую» тему на семинаре?

## Синтез Л9

1. Topic modeling = генератор гипотез о скрытых семантических полях корпуса.
2. Сначала слова и документы-подтверждения, потом имя темы — не наоборот.
3. Умение убить плохую тему важнее умения назвать красивую.

### К следующей встрече — ориентиры

- Д. М. Блей и соавт. (Blei et al.). Latent Dirichlet Allocation. 2003.
- Ф. Моретти. Дальнее чтение. М.: Изд-во Института Гайдара, 2016.
- М. П. Ив (Eve). The Digital Humanities and Literary Studies. 2022.
- К семинару С10 — таблица верификации и одна отвергнутая тема.

## Задание к семинару С10

### Одностраничный протокол


- 1) Корпус  $\geq 6-8$  документов (главы/рассказы).
- 2) Описание очистки и решения об именах.
- 3) LDA хотя бы при двух значениях  $K$ .
- 4) Таблица верификации  $\geq 3$  тем.
- 5) Одна тема-отказ с аргументом (шум/имена/рутина).

### На занятии

Без столбца «сомнения» — не к дискуссии.

Начните с вопроса: что здесь артефакт?

### Логика семестра



Независимые сигналы разных методов сильнее одного красивого метода.