

Автоматическая подготовка и очистка текста к анализу

Цель занятия

Сгенерировать скрипт очистки TXT от издательского мусора и артефактов OCR с контролем потерь.

Основное содержание

- 1. Инвентаризация шумов: сноски, колонтитулы, переносы, OCR.
- 2. Технический промпт с перечнем правил очистки.
- 3. Тест на фрагменте → прогон на полном тексте.
- 4. Сравнение «до/после» по объёму и топ-частотам.

Вопросы для работы на занятии

- 1. Что нельзя удалять без филологического обоснования?
- 2. Как обнаружить, что RegEx «съел» значимые элементы?
- 3. Нужен ли нижний регистр уже на этапе очистки?
- 4. Как документировать правила очистки?

Основные проблемы для обсуждения

- 1. Чрезмерная очистка, стирающая регистр имён и пунктуацию.
- 2. OCR-мусор как ложная редкая лексика.
- 3. Правки только в чате без итогового скрипта.

Литература (2–4 позиции)

- 1. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородкин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.
- 2. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 3. Волженина Е. Гид по Voyant Tools: подготовка корпуса // Системный Блок : [электронный ресурс]. — URL: <https://sysblok.ru/philology/gid-po-voyant-tools-podgotovka-korporusa/> (дата обращения: 18.09.2026).