

Анатомия текстовых данных и среда разработки Cursor

Ключевые определения (по источникам курса)

- Оцифровка — перевод объекта в цифровую форму; в монографии СФУ подчёркивается, что она не только ускоряет доступ, но и всегда есть форма абстрагирования, где возможны потери и ошибки распознавания/кодирования.
- «Грязные данные» — тексты с ошибками OCR, некорректной кодировкой, смешением редакций и издательским мусором; такие искажения способны менять частотные и стилиометрические выводы (монография СФУ, 2023; логика курса).
- UTF-8 — стандарт кодировки, критичный для кириллицы; TXT/XML/JSON — базовые форматы хранения «плоского» и структурированного текста в цифровом исследовании.

Содержание лекции

Для компьютера художественный текст — прежде всего данные. Буквы кодируются, файл имеет формат, в тексте могут остаться колонтитулы, сноски, артефакты OCR и следы чужой вёрстки. Любой последующий анализ — частоты, NER, сети, topic modeling, sentiment — наследует качество входа. Поэтому цифровой филолог начинает не с «красивой интерпретации», а с контроля формы данных: какая редакция, какая кодировка, откуда файл, что уже удалено и что ещё предстоит очистить.

Монография СФУ специально обсуждает оцифровку как абстрагирование: ускоряя доступ, мы неизбежно что-то теряем и рискуем внести ошибки распознавания и кодирования. «Грязные данные» опасны тем, что выглядят «уже цифровыми» и потому кажутся точными. На деле неверная кодировка кириллицы, смешение редакций или мусор OCR способны исказить частотный профиль и стилиометрический отпечаток сильнее, чем любой тонкий теоретический спор. Пособие ИТМО связывает предобработку с достоверностью алгоритмов напрямую: чем чище вход, тем осмысленнее выход.

Базовая гигиена курса: UTF-8 для кириллицы; единый рабочий TXT для «плоского» анализа; понимание, когда нужны XML/JSON (разметка, экспорт сущностей, ответы API). Регулярные выражения и скрипты очистки можно генерировать в Cursor, но каждое правило удаления должно быть филологически осознанным. Удалить номера страниц — обычно безопасно; удалить все заглавные буквы до нормализации имён — уже рискованно; вырезать

«короткие строки» без проверки — можно снести ремарки драмы или стихотворный графический ритм.

Cursor в программе курса — не «ещё один чат», а AI-native лаборатория. Важны три практики. Первая: держать исходники, скрипты, результаты и заметки в отдельных папках (/texts, /scripts, /output, /notes). Вторая: давать модели контекст через @Files, а не пересказывать файл словами. Третья: идти маленькими шагами — сначала фрагмент, потом полный текст; сначала измерение, потом очистка; сначала таблица, потом график. Composer полезен, когда нужно согласованно править несколько файлов пайплайна, но он не отменяет чтения предложенного кода на уровне логики шагов.

Воспроизводимость здесь важнее разового успеха. В гуманитарном проекте легко потерять цепочку: откуда текст, какая редакция, какой промпт породил скрипт, что именно считалось словом. Хороший стандарт занятия: рядом с числом или графиком лежат исходник, скрипт (или зафиксированный промпт) и краткий лог решений. Тогда финальная Streamlit-панель в конце семестра будет исследовательским артефактом, а не магическим демо.

Практический вывод лекции: среда разработки — продолжение филологической лаборатории. ИИ снижает порог входа в программирование для магистранта с «нулевым» кодингом, но усиливает требование специфицировать задачу. Исследователь, который не умеет объяснить, что должно получиться на выходе, не сможет ни проверить код, ни интерпретировать результат.

Вопросы для закрепления

- 1. Что исследователь теряет и что приобретает при оцифровке текста?
- 2. Почему единый UTF-8 TXT — обязательный старт анализа?
- 3. Как структура папок проекта повышает воспроизводимость?

Литература

- 1. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородкин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.
- 2. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 3. Cursor — AI-native code editor : Documentation : [электронный ресурс]. — URL: <https://docs.cursor.com/> (дата обращения: 18.09.2026).