

Лемматизация и частотный анализ текста

Цель занятия

Построить частотный словарь после токенизации, лемматизации и фильтрации стоп-слов.

Основное содержание

- 1. Пайплайн: токены → леммы → стоп-слова → частоты.
- 2. Топ-50; экспорт в таблицу.
- 3. Сравнение до/после лемматизации.
- 4. Краткий комментарий о лексическом каркасе текста.

Вопросы для работы на занятии

- 1. Когда стоп-слова нельзя удалять?
- 2. Почему имя героя может доминировать в топе?
- 3. Чем частотный список отличается от keywords относительно фона?
- 4. Как длина текста влияет на устойчивость топа?

Основные проблемы для обсуждения

- 1. Ошибки лемматизатора на архаизмах/поэтизмах.
- 2. Смещение омографов и вариантов имени.
- 3. Чтение частот как «главных тем» без проверки.

Литература (2–4 позиции)

- 1. Bird S., Klein E., Loper E. Natural Language Processing with Python : [электронный ресурс]. — URL: <https://www.nltk.org/book/> (дата обращения: 18.09.2026).
- 2. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 3. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородкин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.