

Репрезентативность электронных текстовых коллекций

Цель занятия

Оценить качество цифровых источников и цену «грязных данных».

Основное содержание

- 1. НКРЯ: выборка, разметка, поиск.
- 2. Искажения: OCR, кодировки, неполные издания, смешение редакций.
- 3. Практикум оценки источника под конкретный вопрос.
- 4. Карточка метаданных происхождения текста.

Вопросы для работы на занятии

- 1. Что значит репрезентативный корпус для истории русской литературы?
- 2. Как ошибка OCR меняет частотный профиль?
- 3. Чем опасны случайные интернет-копии?
- 4. Какие метаданные обязательны?

Основные проблемы для обсуждения

- 1. Скрытая неполнота (канон вместо поля литературы).
- 2. Смешение переводов/переизданий.
- 3. Иллюзия точности из-за «цифрового» файла.
- 4. Игнор эдиционной истории.

Литература (2–4 позиции)

- 1. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородкин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.
- 2. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 3. Моретти Ф. Дальнее чтение / пер. с англ. А. Вдовина, О. Собчука, А. Шели ; науч. ред. пер. И. Кушнарева. — М. : Изд-во Института Гайдара, 2016. — 352 с.