

Основы корпусной филологии и предобработка текста

Ключевые определения (по источникам курса)

— Корпус — не «просто большой текст»: в логике корпусной лингвистики (которую Моретти прямо противопоставляет наивному представлению о «тексте в большом объёме») корпус — организованная коллекция для анализа, а не коммуникативное событие «со смыслом» в обычном литературоведческом смысле.

— Токенизация — деление текста на единицы анализа (слова/знаки); лемматизация — приведение словоформ к начальной форме; стемминг — более грубая обрезка основы. Для русского языка лемматизация особенно важна из-за богатой морфологии.

— НКРЯ и Google Books Ngram Viewer — примеры инфраструктуры корпусного/культуромического поиска частот и контекстов (обсуждаются в программе курса и в монографии СФУ в связи с n-граммами).

Содержание лекции

Корпусная филология переводит литературоведа от интуиции «так обычно бывает в тексте» к проверяемому распределению форм. Корпус — не папка с книгами и не «просто текст в большом объёме». Моретти, опираясь на корпусную лингвистику, подчёркивает принципиальный сдвиг: когда основой работы становятся корпуса, меняется сама единица исследования. Корпус не «говорит» с нами как коммуникативное событие; у него нет смысла в обычном литературоведческом понимании. Смысл появляется, когда филолог задаёт вопрос, выбирает процедуру и интерпретирует паттерн.

Инфраструктуры вроде НКРЯ и Google Books Ngram Viewer дают разные возможности. НКРЯ полезен размеченными примерами употреблений и поиском по лингвистическим параметрам; Ngram Viewer — для частотных траекторий слов во времени. Монография СФУ подробно показывает, как культуромика на базе оцифрованных книг открывает исторические сдвиги языка и одновременно несёт смещения выборки: библиотечный перекося, неравномерность по годам, ошибки OCR. Для магистерского проекта это урок: любой внешний корпус нужно читать критически, а собственный — документировать.

Предобработка включает токенизацию, лемматизацию, стемминг, фильтрацию стоп-слов и морфологический контроль. Для русского языка лемматизация особенно важна: без неё «дом /

дома / домом» распадаются на разные единицы, и частотный портрет автора искажается. Вместе с тем лемматизация может стереть стилистически значимые формы. Решение всегда зависит от вопроса: изучаем ли мы идиолект частиц и оценочной модальности, или нам нужен тематический каркас лемм.

Пособие ИТМО настаивает на жёсткой связи «чистота данных → качество модели». Сноски, колонтитулы, ссылки, двухколоночная вёрстка, англоязычные вставки в PDF ломают и частоты, и topic modeling. ИИ ускоряет рутину очистки, но не решает за исследователя, что считать мусором. OCR-ошибка может выглядеть как редкое «интересное» слово и попасть в топ. Стоп-слово может быть ключом к интонации повествователя. Поэтому контрольная ручная выборка — часть метода.

Различайте исследовательский корпус (собран под ваш вопрос) и справочный/национальный (фон сравнения). Keywords и коллокации имеют смысл относительно фона: иначе «ключевость» легко принять за простую частотность внутри одного текста. Практически это означает двухконтурную работу: сначала внутренний профиль произведения, затем — при возможности — сопоставление с более широким корпусом эпохи, жанра или автора.

Методологический каркас лекции, который проходит через весь курс: источник → очистка → нормализация → измерение → интерпретация. Пропуск любого звена делает красивую визуализацию методологически слабой. Корпусная грамотность — это и есть умение держать всю цепочку прозрачной.

Вопросы для закрепления

- 1. Чем корпус отличается от папки с книгами?
- 2. Когда лемматизация необходима, а когда стирает значимые формы?
- 3. Какие типы издательского мусора чаще всего портят анализ?

Литература

- 1. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 2. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.
- 3. Моретти Ф. Дальнее чтение / пер. с англ. А. Вдовина, О. Собчука, А. Шели ; науч. ред. пер. И. Кушнарева. — М. : Изд-во Института Гайдара, 2016. — 352 с.