

Квантитативные методы и закон Ципфа в литературоведении

Ключевые определения (по источникам курса)

- Закон Ципфа (по монографии СФУ): если слова корпуса упорядочить по убыванию частоты, частота n -го слова приблизительно обратно пропорциональна его рангу; при этом редкие слова составляют огромную долю словарного списка (в обсуждении Google Books — «тёмная материя лексикона»).
- Частотный словарь — базовый лексический профиль текста: показывает каркас употреблений, но сам по себе не равен интерпретации смысла.
- TTR (type–token ratio) — отношение числа уникальных словоформ (types) к общему числу словоупотреблений (tokens); мера лексического разнообразия, чувствительная к длине текста.

Содержание лекции

Квантитативные методы в литературоведении исходят из простой и сильной предпосылки: стиль оставляет измеримый след. Частотный словарь, распределение длин слов и предложений, повторяемость лексики, коллокации и keywords не «объясняют роман», но дают карту, по которой можно двигаться к интерпретации идиостиля. Моретти показывает, как счёт и модели помогают видеть жанровые формулы, исторические сдвиги и большие паттерны; пособие ИТМО вписывает частотный анализ в повседневную практику ДН-проектов.

Закон Ципфа описывает типичное устройство частотного списка: немного слов встречаются очень часто, а длинный хвост редких слов занимает огромную долю словаря. В монографии СФУ это используется, в частности, при обсуждении Google Books и «тёмной материи лексикона»: словари хорошо покрывают высокочастотное ядро, но редкие слова составляют около половины общего списка и часто остаются вне традиционной лексикографии. Для филолога отсюда два вывода. Первый: топ-50 — ещё не весь язык произведения. Второй: аномалии хвоста и ядра нужно читать осторожно — это может быть и поэтика, и мусор предобработки.

Индекс TTR (type–token ratio) оценивает лексическое разнообразие, но чувствителен к длине текста. Сравнить новеллу и роман «в лоб» нельзя: у короткого текста TTR обычно выше по чисто статистическим причинам. Корректное сравнение требует сопоставимого объёма (или скользящих окон), единой нормализации и жанровой оговорки. Иначе метрика начинает

морализировать: «богатый словарь / бедный словарь» вместо анализа поэтики повтора, сказовости, канцелярита или экспериментальной редукции.

Keywords и коллокации переводят нас от «что часто» к «что характерно» и «что склеивается». Ключевые слова относительно фонового корпуса помогают увидеть отличие текста от нормы эпохи или жанра. Коллокации показывают устойчивые пары и тройки, в которых часто прячется образная или идеологическая связка. Но статистическая связь не равна тропу автоматически: кандидат должен быть возвращён в контекст и проверен чтением.

Диагностический порядок курса таков: сначала проверить, не ломает ли предобработка профиль; затем посмотреть, похож ли текст на ожидаемое цифровое распределение; затем интерпретировать аномалии. Всплеск имён может говорить о персонажной плотности сюжета; всплеск «издательских» слов — о плохой очистке; ровный «бедный» словарь — о сознательной поэтике ограничения. Только после этой диагностики цифра становится аргументом.

Связка лекции с практикой и семинаром: частотный словарь — материал для ПЗ/С4, а не финальный вердикт об авторе. Хороший отчёт всегда показывает и таблицу, и цитату, и оговорку о методе.

Вопросы для закрепления

- 1. Что измеряет частотный словарь и чего он не измеряет?
- 2. Почему редкие слова важны при обсуждении закона Ципфа?
- 3. Как корректно сравнивать лексическое разнообразие двух авторов?

Литература

- 1. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородкин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.
- 2. Моретти Ф. Дальнее чтение / пер. с англ. А. Вдовина, О. Собчука, А. Шели ; науч. ред. пер. И. Кушнарева. — М. : Изд-во Института Гайдара, 2016. — 352 с.
- 3. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.