

Автоматическое извлечение персонажей и локаций (NER)

Цель занятия

Собрать через Natasha (или аналог) списки PER/LOC и выгрузить в Excel после нормализации.

Основное содержание

- 1. Скрипт извлечения и частот сущностей.
- 2. Слияние вариантов имён; удаление ложных срабатываний.
- 3. Отдельные топы персонажей и топонимов.
- 4. Краткая интерпретация мира произведения.

Вопросы для работы на занятии

- 1. Как объединять варианты имени одного героя?
- 2. Чем опасна омонимия топонима?
- 3. Считать ли мифологические имена персонажами?
- 4. Как NER готовит сетевой анализ?

Основные проблемы для обсуждения

- 1. Завышение числа персонажей.
- 2. Пропуск описательных именованных («старик», «гость»).
- 3. Экспорт без словаря нормализации.

Литература (2–4 позиции)

- 1. Официальная документация NLP-библиотеки Natasha : [электронный ресурс]. — URL: <https://natasha.github.io/> (дата обращения: 18.09.2026).
- 2. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 3. Bird S., Klein E., Loper E. Natural Language Processing with Python : [электронный ресурс]. — URL: <https://www.nltk.org/book/> (дата обращения: 18.09.2026).