

Автоматическое извлечение знаний: NER-технологии

Ключевые определения (по источникам курса)

- NER (Named Entity Recognition) — извлечение именованных сущностей: слов, обозначающих предмет/явление определённой категории с индивидуальным обозначением (имя человека, топоним, название организации и т.п.). Пример из пособия ИТМО: «корабль»
- сущность, «корабль Мария» — именованная сущность.
- NLP (Natural Language Processing) — область на пересечении информатики и лингвистики, цель которой — обработка и «понимание» естественного языка: извлечение знаний, классификация, перевод, определение тематик и др. (Пучковская и др., 2021).
- Natasha — русскоязычный NLP-стек для задач вроде морфологии и NER; практический инструмент курса для извлечения персонажей и локаций.

Содержание лекции

NER (Named Entity Recognition) — одна из центральных NLP-задач для цифрового литературоведения. По определению пособия ИТМО, именованные сущности — это слова, обозначающие предмет или явление определённой категории и имеющие индивидуальное обозначение: имя человека, топоним, название организации, иногда даты и иные маркеры. Разница между «корабль» и «корабль Мария» здесь принципиальна: алгоритм должен научиться видеть именно индивидуацию в языковой ткани.

Зачем это филологу? Чтобы автоматически собрать «перечень мира» произведения и перейти к следующим уровням анализа: частоте появления героев, карте пространства, динамике имён по главам, сетевым связям. NER превращает сплошной текст в структуру, с которой уже можно работать как с данными. Пособие ИТМО подчёркивает и практическую сторону: сущности удобно заносить в таблицы/базы; кроме того, имена часто ведут себя как устойчивые коллокации, которые нельзя бездумно разбивать при предобработке.

Ограничение метода столь же важно, как и сила. Алгоритм классифицирует последовательности токенов, а не «понимает» роман. Типичные ошибки на художественном материале: омонимия; прозвища и перифразы («старик», «гостья», «наш герой»); мифологические и аллегорические имена; метонимия; варианты имени одного лица (Алексей /

Алёша / Карамазов). Модели, обученные на новостных текстах, иначе работают на языке XIX века с отчествами, церковно-календарными формами и говорящими фамилиями.

Поэтому обязательный этап курса — ручная нормализация. Слияние вариантов имени, удаление ложных срабатываний, отделение реальных топонимов от метафорических — это не «отступление от автоматизации», а филологическая часть пайплайна. Без неё последующие графы и карты пространства будут красиво врать.

В инструментальном плане курс опирается на Natasha как русскоязычный контур и на общую NLP-грамотность (NLTK/SpaCy как рамка задач). ИИ в Cursor ускоряет написание скрипта извлечения и экспорта в Excel, но качество исследования определяется словарём сущностей после правки. Практическая связка: П5 даёт списки, П6 строит пространство, П7–П8 собирают сеть персонажей.

Методологический вывод: NER — мост между текстом и структурированной базой знаний о произведении. Он ускоряет сбор материала для интерпретации хронотопа и системы образов, но не заменяет знание поэтики имени и роли героя в сюжете.

Вопросы для закрепления

- 1. Чем именованная сущность отличается от «просто сущности»?
- 2. Почему варианты имени ломают наивный подсчёт персонажей?
- 3. Как связать NER-список с вопросом о хронотопе?

Литература

- 1. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 2. Официальная документация NLP-библиотеки Natasha : [электронный ресурс]. — URL: <https://natasha.github.io/> (дата обращения: 18.09.2026).
- 3. Bird S., Klein E., Loper E. Natural Language Processing with Python : [электронный ресурс]. — URL: <https://www.nltk.org/book/> (дата обращения: 18.09.2026).
- 4. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородкин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.