

Тематическое моделирование художественной прозы

Ключевые определения (по источникам курса)

- Тематическое моделирование (topic modeling) — способ построить модель корпуса, которая определяет, к каким темам относится каждый документ; тема мыслится как набор терминов, документ — как смесь тем в разных пропорциях (Пучковская и др., 2021).
- LDA (латентное размещение Дирихле) — один из классических алгоритмов topic modeling, часто используемый как генератор гипотез о скрытых семантических полях/мотивах.
- Препроцессинг критичен: без очистки ссылок, сносок и «мусора» тематическая модель «работает очень плохо» (формулировка пособия ИТМО).

Содержание лекции

Тематическое моделирование (topic modeling) — способ построить модель корпуса, которая определяет, к каким темам относится каждый документ. По пособию ИТМО, тема мыслится как набор терминов, чаще встречающихся вместе; документ — как смесь тем в разных пропорциях. Классический алгоритм LDA (латентное размещение Дирихле) математически закрепляет эту интуицию и выдаёт исследователю кластеры статистически связанных слов.

Для филолога это инструмент поиска скрытых семантических полей, мотивов и лейтмотивов, особенно когда текст велик или корпус включает много произведений. Можно смотреть эволюцию тем по главам одного романа или по периодам творчества. Здесь метод родственен дальнему чтению Моретти: изменение масштаба меняет видимость структуры. Но «тема» алгоритма — не готовый литературоведческий мотив. Мотив предполагает повторяемость значимого содержания в сюжете и образной системе; статистический кластер может быть и мотивом, и артефактом.

Пособие ИТМО особо подчёркивает роль препроцессинга. Ссылки, сноски, колонтитулы, «грязный» PDF, неотфильтрованные имена и служебная лексика делают тематическую модель почти бесполезной: вместо мотивов получаются кластеры мусора. Чем чище корпус, тем точнее результат. Отсюда прямая связь лекции с корпусной гигиеной Л2–Л3 и практикой очистки.

Интерпретационная процедура должна быть явной. Сначала подобрать число тем и проверить устойчивость при небольших изменениях параметров. Затем назвать темы осторожно, опираясь на опорные слова. Затем найти эпизоды-подтверждения. Затем сравнить с

традиционными исследованиями избранного произведения. Если «мотив» исчезает при лёгкой смене параметров, его статус гипотетический.

Полезная учебная форма — таблица верификации: тема LDA | предложенное имя | опорные слова | подтверждённые эпизоды | сомнения. На семинаре С10 такая таблица позволяет быстро отличить эвристически ценный кластер от шума и обсудить риск ретрофита (подгонки названия под желаемый тезис).

Отдельно стоит помнить о роли имён и жанровых формул: они легко образуют ложные «темы». Поэтому в предобработке для topic modeling имена часто выносят в отдельный слой (или временно маскируют), а затем возвращают в интерпретацию уже как персонажную/хронотопическую структуру, а не как «мотив» сам по себе.

Вывод лекции: topic modeling — генератор гипотез о семантической структуре корпуса. Его сила в обнаружении неочевидных повторов; его слабость — в отсутствии понимания сюжета, тропа и авторской стратегии. Филолог переводит «мешок слов» в проверяемый исследовательский тезис.

Вопросы для закрепления

- 1. Почему вывод LDA нельзя напрямую называть мотивом?
- 2. Как проверить устойчивость темы?
- 3. В каких задачах topic modeling особенно полезен филологу?

Литература

- 1. Пучковская А. А., Зими́на Л. В., Волков Д. А. Введение в цифровые гуманитарные исследования : учебно-методическое пособие. — СПб : Университет ИТМО, 2021. — 61 с.
- 2. Цифровые гуманитарные исследования : монография / А. Б. Антопольский, А. А. Бонч-Осмоловская, Л. И. Бородкин [и др.]. — Красноярск : Сиб. федер. ун-т, 2023. — 272 с.
- 3. Моретти Ф. Дальнее чтение / пер. с англ. А. Вдовина, О. Собчука, А. Шели ; науч. ред. пер. И. Кушнарева. — М. : Изд-во Института Гайдара, 2016. — 352 с.